МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РФ

Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский Авиационный Институт» (Национальный Исследовательский Университет)

Институт: №8 «Информационные технологии и прикладная математика»

Кафедра: 806 «Вычислительная математика и программирование»

Лабораторная работа № 1
по курсу «Глубокое обучение
и искусственный интеллект»

Группа: М8О-307Б-23

Студенты: Усов Сергей, Попов Владимир, Мария Люзина, Жиденко Виктория, Агейкин Егор

Преподаватель: Сошников Д.В

Оценка:

Дата: 11.03.2026

Москва, 2026

Оглавление

1. Введение

1.1. Цель и задачи работы

1.2. Общая постановка задачи

2. Анализ и извлечение знаний

2.1. Анализ структурированных источников (WikiData, DBPedia)

2.2. Методы извлечения знаний (SPARQL)

3. Концептуализация и онтология

3.1. Построение онтологии предметной области

3.2. Описание и визуализация связей

4. Генерация и интеграция контента

4.1. Настройка директорий для работы

4.2. Экспорт данных из Wikidata

4.3. Использование генеративных ИИ-моделей (LLM API)

4.4. Механизм простановки перекрестных ссылок

5. Заключение

5.1. Основные результаты и выводы

1. Введение

1.1. Цель и задачи работы

Цель работы состоит в коллективном создании фрагмента детской энциклопедии по выбранному тематическому разделу с использованием современных методов и инструментов искусственного интеллекта.

Ключевыми инструментами при этом являются:

- методы и инструменты явного представления знания (например, WikiData, DBPedia);
- генеративные ИИ-модели (LLM API, такие как DeepSeek, YandexGPT, GigaChat и др.).

Для достижения поставленной цели были сформулированы следующие **задачи**:

1. **Анализ и извлечение знаний:** Изучить существующие структурированные базы знаний (WikiData, DBPedia) по выбранной теме и извлечь необходимые фрагменты знаний, используя язык запросов SPARQL.
2. **Концептуализация и онтология:** Разработать концептуализацию предметной области, построить онтологию (минимум 15 понятий), описать и визуализировать ее, включая иерархические и горизонтальные связи.
3. **Генерация контента:** Сгенерировать markdown-странички для всех понятий с помощью генеративных ИИ-моделей, используя промпт, адаптированный для объяснения десятилетнему ребенку.
4. **Интеграция контента:** Разработать скрипт на Python для автоматической простановки перекрестных ссылок между созданными статьями, а также интегрировать все полученные материалы (отчет, код, сгенерированные тексты) в репозиторий..

1.2. Общая постановка задачи и предметная область

Для реализации поставленной цели и задач была выбрана конкретная предметная область — **«Твои права и обязанности»** (раздел «Общество и взаимодействие людей»).

В рамках данной предметной области была произведена концептуализация, включающая **15 ключевых понятий** (согласно требованию ТЗ), которые легли в основу построения онтологии и последующей генерации статей детской энциклопедии.

2. Анализ и извлечение знаний

2.1. Анализ структурированных источников (WikiData, DBPedia)

Работа над проектом началась с глубокого анализа выбранной предметной области — **«Твои права и обязанности»** (раздел «Общество и взаимодействие людей») — в крупнейших структурированных источниках знаний, в частности, в **WikiData**.

Основная задача на данном этапе заключалась в идентификации ключевых понятий и получении для них структурированной информации (идентификаторы, описания) для последующего построения онтологии и генерации контента.

В результате анализа было отобрано 15 базовых понятий, соответствующих требованиям технического задания. К ним относятся:

- **Базовые понятия:** Человек, Право, Обязанность, Закон, Конституция.
- **Конкретные права:** Право на образование, Право на имя, Неприкосновенность частной жизни, Безопасность.
- **Конкретные обязанности:** Обязанность учиться, Обязанность беречь природу.
- **Социальные институты:** Семья, Школа, Полиция, Гражданин.

2.2. Методы извлечения знаний (SPARQL)

Для программного взаимодействия с WikiData и извлечения необходимого подграфа знаний был использован язык запросов **SPARQL**. Это позволило получить точные данные, избегая ручного сбора информации.

Было составлено несколько типов запросов, каждый из которых решал свою задачу:

1. **Извлечение основных данных:** Запрос, который по списку Wikidata ID извлекал метки (?itemLabel) и краткие описания (?itemDescription) всех 15 основных понятий.

   Пример запроса на извлечение базовой информации:

```
SELECT ?item ?itemLabel ?itemDescription WHERE {
  VALUES ?item {
    wd:Q5          # Человек
    wd:Q956115     # Право
    wd:Q878070     # Обязанность
    wd:Q7748       # Закон
    wd:Q7755       # Конституция
    wd:Q907751     # Право на образование
    wd:Q8436       # Семья
    wd:Q1518783    # Право на имя
    wd:Q2526134    # Безопасность
    wd:Q159491     # Неприкосновенность частной жизни
    wd:Q3503200    # Обязанность учиться
    wd:Q83223793   # Обязанность беречь природу (охрана окружающей среды)
    wd:Q3914       # Школа
    wd:Q35535      # Полиция
    wd:Q215627     # Гражданин
  }
  SERVICE wikibase:label { bd:serviceParam wikibase:language "ru,en". }
}
```

2. **Построение иерархических связей (Онтология):** Запросы с использованием свойства wdt:P279 (подкласс от), которые позволили определить иерархическую структуру понятий (например, что является подклассом «Права» или «Обязанности»). Это легло в основу построения онтологии (Раздел 3).

   Пример запроса на поиск суперкласса:

```
SELECT ?item ?itemLabel ?superclass ?superclassLabel WHERE {
  VALUES ?item {
    wd:Q956115     # Право
    wd:Q878070     # Обязанность
    wd:Q907751     # Право на образование
    wd:Q159491     # Неприкосновенность частной жизни
    wd:Q3503200    # Обязанность учиться
    wd:Q83223793   # Обязанность беречь природу
    wd:Q215627     # Гражданин
  }
  OPTIONAL { ?item wdt:P279 ?superclass. }   # P279 = подкласс
  SERVICE wikibase:label { bd:serviceParam wikibase:language "ru". }
}
```

3. **Поиск горизонтальных и экземплярных связей:** Были составлены запросы для поиска конкретных экземпляров (wdt:P31) классов (например, поиск Конституций различных стран или поиск конкретных примеров школ и полицейских участков), что обогатило модель знаний горизонтальными связями.

   Пример запроса на поиск экземпляров (Инстансов):

```
SELECT ?instance ?instanceLabel WHERE {
  ?instance wdt:P31 ?class.        # экземпляр класса
  VALUES ?class { wd:Q3914 wd:Q35535 }   # школа, полиция
  SERVICE wikibase:label { bd:serviceParam wikibase:language "ru". }
}
LIMIT 20
```

Также применялся специализированный метод обхода графа с помощью сервиса gas:service для визуализации и более широкого извлечения связей в подграфе знаний, что является продвинутой техникой для работы с онтологиями.

```
#defaultView:Graph
PREFIX gas: <http://www.bigdata.com/rdf/gas#>

SELECT DISTINCT ?item1 ?item1Label ?item2 ?item2Label WHERE {
  {
    SELECT ?item1 ?item2 WHERE {
      SERVICE gas:service {
        gas:program gas:gasClass "com.bigdata.rdf.graph.analytics.BFS" ;
                    gas:in wd:Q956115 ;            # стартовая вершина – Право
                    gas:traversalDirection "Forward" ;
                    gas:out ?item1 ;
                    gas:out1 ?depth1 ;
                    gas:out2 ?item2 ;
                    gas:linkType wdt:P279 .         # отношение подкласса
      }
    }
  }
  SERVICE wikibase:label { bd:serviceParam wikibase:language "ru,en". }
}
```

3. Концептуализация и онтология

3.1. Построение онтологии предметной области

На основе анализа структурированных источников (Раздел 2) и требований технического задания была разработана концептуализация предметной области **«Твои права и обязанности»**.

Онтология предметной области представляет собой формальное представление знаний, которое включает 15 ключевых понятий:

- **Базовые понятия:** Человек, Право, Обязанность, Закон, Конституция.
- **Конкретные права:** Право на образование, Право на имя, Неприкосновенность частной жизни, Безопасность.
- **Конкретные обязанности:** Обязанность учиться, Обязанность беречь природу.
- **Социальные институты/Субъекты:** Семья, Школа, Полиция, Гражданин.

Цель построения онтологии — создание структурированной и взаимосвязанной модели, которая послужит основой для программной генерации статей и автоматической простановки перекрестных ссылок.

3.2. Описание и визуализация связей

В разработанной онтологии были определены два основных типа связей, обеспечивающих полноту модели: иерархические и функциональные.

Визуализация онтологии (Граф Mermaid.js)

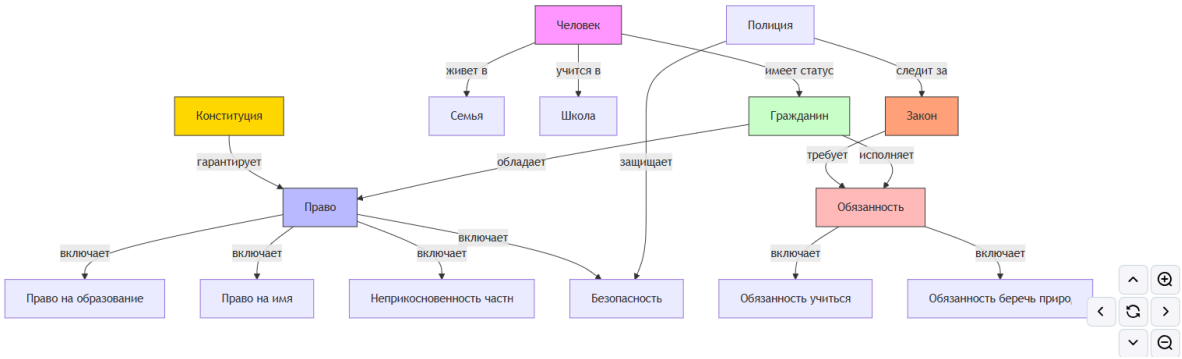

4. Генерация и интеграция контента

4.1. Настройка директорий для работы

Для обеспечения корректной интеграции сгенерированного контента в структуру репозитория (согласно требованиям ТЗ) и последующего размещения на GitHub Pages был разработан скрипт
web_structure.py
. Его основные функции:

1. **Создание структуры:** Автоматическое создание целевых папок
   articles
   (для статей) и
   images
   (для иллюстраций) внутри раздела
   WEB
   .
2. **Генерация навигационных файлов:** Создание служебных Markdown-файлов
   index.md
   (главная страница раздела с таблицей понятий) и
   glossary.md
   (полный словарь терминов) для удобной навигации пользователя по энциклопедии.

Этот шаг обеспечивает единообразие структуры и готовность проекта к приему сгенерированных файлов. Реализация - https://github.com/sergey162/2026_kidbook/blob/14_team/WORK/2.1_society/rights_and_responsibilites/src/init_web_structure.py

4.2. Экспорт данных из Wikidata

Несмотря на то, что основные запросы SPARQL были выполнены на этапе **Раздела 2**, был написан вспомогательный Python-скрипт для программного экспорта и сохранения детальной информации из WikiData.

Скрипт использует публичный API WikiData для получения актуальных русских и английских меток (labels) и описаний (descriptions) для каждого из 15 выбранных понятий (по их Q-идентификатору). Полученные данные о каждом понятии сохраняются в структурированный JSON-файл (wikidata_export.json) в папке raw_data.

Цель этого шага — иметь локальный, машиночитаемый источник данных, который можно использовать для:

- Верификации данных.
- Дополнительного обогащения промптов перед генерацией текста.
- Отображения точных ссылок и описаний в служебных файлах (например, в словаре терминов).

Реализация - https://github.com/sergey162/2026_kidbook/blob/14_team/WORK/2.1_society/rights_and_responsibilites/src/fetch_wikidata.py

4.3. Использование генеративных ИИ-моделей (LLM API)

Для автоматической генерации статей детской энциклопедии, как того требовало техническое задание, был разработан скрипт на Python, использующий API генеративных ИИ-моделей.

В качестве основного инструмента был выбран сервис **OpenRouter**, предоставляющий доступ к различным крупным языковым моделям (LLM), в частности, к модели **Qwen-2.5-72B-Instruct**. Это позволило получить качественные тексты, соответствующие заданной стилистике и объему.

Ключевым аспектом являлась разработка специализированного **промпта**, адаптированного для целевой аудитории (дети 10-12 лет). Промпт включал следующие требования:

- **Аудитория и тон:** Дружелюбный тон, обращение на «ты», объяснение сложных понятий простыми словами.
- **Структура статьи:** Четкая пятичастная структура для единообразия и легкого восприятия:
    1. Введение — что это такое простыми словами.
    2. Основная часть — как это работает в реальном мире.
    3. Примеры из жизни школьника (минимум 3 примера).
    4. Интересные факты (2-3 факта).
    5. Заключение — краткий вывод.
- **Оформление:** Использование разметки Markdown (заголовки, списки, жирный текст) и эмодзи для повышения живости и привлекательности текста.

Скрипт также включал функционал для опциональной генерации иллюстраций к каждой статье, используя различные открытые сервисы (Pollinations.ai, Lorem Picsum) с системой резервирования, чтобы обеспечить визуальное наполнение энциклопедии. Реализация - https://github.com/sergey162/2026_kidbook/blob/14_team/WORK/2.1_society/rights_and_responsibilites/src/link_concepts.py

4.4. Механизм простановки перекрестных ссылок

Для выполнения задачи по интеграции контента и создания взаимосвязанного графа статей был разработан второй Python-скрипт, реализующий механизм автоматической простановки перекрестных ссылок.

Основная техническая сложность заключалась в необходимости учета **морфологии русского языка**, так как понятия в тексте могут встречаться в различных падежах («Право», «Права», «Правом» и т.д.). Для решения этой задачи была использована библиотека **PyMorphy** (или ее аналоги), которая позволяет:

1. **Лемматизировать** (приводить к начальной форме) ключевые понятия из списка concepts.json.
2. Сгенерировать все возможные грамматические формы (лексемы) для каждого из 15 понятий.
3. Произвести поиск в тексте каждой сгенерированной статьи по всем формам слова.

При обнаружении совпадения скрипт автоматически заменял вхождение слова на соответствующую Markdown-ссылку, ведущую на файл статьи с данным понятием, например:
[Право](./right.md)
Таким образом, обеспечивается высокая степень связности контента, что позволяет читателю (ребенку) легко переходить между связанными понятиями, углубляя свои знания по предметной области. Дополнительно в скрипте реализован механизм экранирования уже существующих ссылок, чтобы избежать их порчи. Реализация - https://github.com/sergey162/2026_kidbook/blob/14_team/WORK/2.1_society/rights_and_responsibilites/src/link_concepts.py

5. Заключение

5.1. Основные результаты и выводы

В ходе выполнения лабораторной работы был успешно реализован полный цикл создания фрагмента детской энциклопедии **«Твои права и обязанности»** с применением методов искусственного интеллекта и работы со структурированными знаниями.

Ключевые результаты работы:

- **Формализация знаний:** На основе анализа WikiData и DBPedia с использованием SPARQL была разработана концептуализация предметной области, включающая **15 ключевых понятий**.
- **Построение Онтологии:** Была создана и визуализирована Онтология, которая отражает не только иерархические связи (подкласс от), но и сложные **функциональные/ассоциативные связи** между понятиями (например, «Конституция гарантирует Право», «Гражданин исполняет Обязанность»), что соответствует критерию полноты и сложности модели знаний.
- **Автоматическая Генерация Контента:** С помощью LLM API (Qwen-2.5-72B-Instruct через OpenRouter) был реализован программный генератор, который создал **15 статей** в формате Markdown. Использование специализированного промпта обеспечило соответствие текстов целевой аудитории (дети 10-12 лет) и строгое соблюдение заданной пятичастной структуры (Введение, Основная часть, Примеры, Факты, Заключение).
- **Интеграция и Связность:** Разработанный Python-скрипт успешно решил задачу **автоматической простановки перекрестных ссылок** в статьях. Благодаря использованию библиотеки PyMorphy, скрипт учитывает морфологию русского языка (падежи), что позволило обеспечить высокий уровень связности контента без ручного редактирования.

В целом, работа продемонстрировала эффективное сочетание классических методов

представления знаний (онтологии, SPARQL) с современными технологиями генеративного ИИ (LLM API) для решения прикладной задачи создания образовательного контента.
Ссылка на репозиторий с решением: WORK - https://github.com/lemito/2026_kidbook/tree/main/WORK/2.1_society/rights_and_responsibilites и WEB - https://github.com/sergey162/2026_kidbook/tree/14_team/WEB/2.1_society/rights_and_responsibilities